

Day01

1. 大数据简介

1.1 大数据的由来

- 1 随着计算机技术的发展，互联网的普及，信息的积累已经到了一个非常庞大的地步，信息的增长也在不断的加快，
2 随着互联网、物联网建设的加快，信息更是爆炸式增长，收集、检索、统计这些信息越发困难，必须使用新的技术来解决这些问题

1.2 什么是大数据

- 1 **【1】定义**
2 大数据指无法在一定时间范围内用常规软件工具进行捕捉、管理和处理的数据集合，需要新处理模式才能具有更强的决策力、洞察发现力和流程优化能力的海量、高增长率和多样化的信息资产
3
4 **【2】总结**
5 大数据是指即从各种各样类型的数据中，获得有价值的信息

1.3 大数据特性

- 1 **【1】大体量 (Volume)**
2 数据体量大,一般从TB级别开始计算，可从数百TB到数十数百PB甚至EB的规模
3 KB、MB、GB、TB、PB、EB、... ..
4 1KB = 1024Bytes
5 1MB = 1024K
6 1GB = 1024M
7 1TB = 1024G
8 1PB = 1024T
9 1EB = 1024P
10
11 **【2】多样性 (Variety)**
12 数据的种类和来源多
13 **【3】时效性 (Velocity)**
14 很多大数据需要在一定的时间限度下得到及时处理
15 **【4】准确性 (Veracity)**
16 处理的结果要保证一定的准确性
17 **【5】大价值 (Value)**

- 18 大数据包含很多深度的价值，大数据分析挖掘和利用将带来巨大的商业价值
- 19
- 20 **【补充】**
- 21 数据的价值密度越来越低，但是这并不意味着想要的的数据越来越少，相反我们想要的的数据是越来越多，但是样本总量的增长速度是要高于想要的的数据的增长速度的

1.4 带来的问题

- 1 **【1】** 数据存储问题 - 存储速度、存储空间
- 2 **【2】** 数据计算|分析问题 - 性能与效率问题

1.5 大数据与Hadoop

- 1 **【1】** Hadoop是什么？
- 2 1.1) Hadoop是一种分析和处理海量数据的软件平台
- 3 1.2) Hadoop是一款开源软件，使用JAVA开发
- 4 1.3) Hadoop可以提供一个分布式基础架构

2. Hadoop简介

2.1 Hadoop概述

2.1.1 Hadoop概念

▪ 定义

Hadoop是Yahoo!开发，后贡献给了Apache的一套开源的、可靠的、可扩展的用于分布式计算的框架

▪ Hadoop作者

Doug cutting

▪ Hadoop名字由来

以Hadoop作者的孩子的一个棕黄色的大象样子的玩具的命名



2.1.2 Hadoop特点

- **高可靠性**

Hadoop按位存储和数据处理的能力值得信赖

- **高扩展性**

Hadoop通过可用的计算机集群分配数据，完成存储和计算任务，这些集群可以方便地扩展到数以千计的节点中，具有高扩展性

- **高效性**

Hadoop能够在节点之间进行动态地移动数据，并保证各个节点的动态平衡，处理速度非常快，具有高效性

- **高容错性**

Hadoop能够自动保存数据的多个副本（默认是3个），并且能够自动将失败的任务重新分配

2.1.3 Hadoop能做什么

- **大数据量存储**

分布式存储（各种云盘，百度，360~还有云平台均有hadoop应用）

- **日志处理**

- **搜索引擎**

如何存储持续增长的海量网页: 单节点 V.S. 分布式存储

如何对持续增长的海量网页进行排序: 超算 V.S. 分布式计算

- **数据挖掘**

目前比较流行的广告推荐

2.1.4 Hadoop版本

- **Hadoop1.0**

包含Common, HDFS和MapReduce, 停止更新

- **Hadoop2.0**

包含了Common, HDFS, MapReduce和YARN。Hadoop2.0和Hadoop1.0完全不兼容。

- **Hadoop3.0**

包含了Common, HDFS, MapReduce, YARN。Hadoop3.0和Hadoop2.0是兼容的

2.2 Hadoop核心组件

2.2.1 HDFS (Hadoop Distributed File System)

- **HDFS**

分布式存储, 解决海量数据的存储

- **HDFS特点及原理**

HDFS具有扩展性、容错性、海量数量存储的特点

原理为将大文件切分成指定大小的数据块, 并在分布式的多台机器上保存多个副本

- **HDFS角色和概念**

1. Client

切分文件、访问HDFS、与NameNode交互获取文件位置信息、与DataNode交互读取和写入数据

2. Namenode

Master节点, 管理HDFS的名称空间和数据块映射信息, 配置副本策略, 处理所有客户端请求

3. Secondarynode

定期同步NameNode, 紧急情况下, 可转正

4. Datanode

数据存储节点, 存储实际的数据


汇报存储信息给NameNode

5. Block

每块默认128MB大小

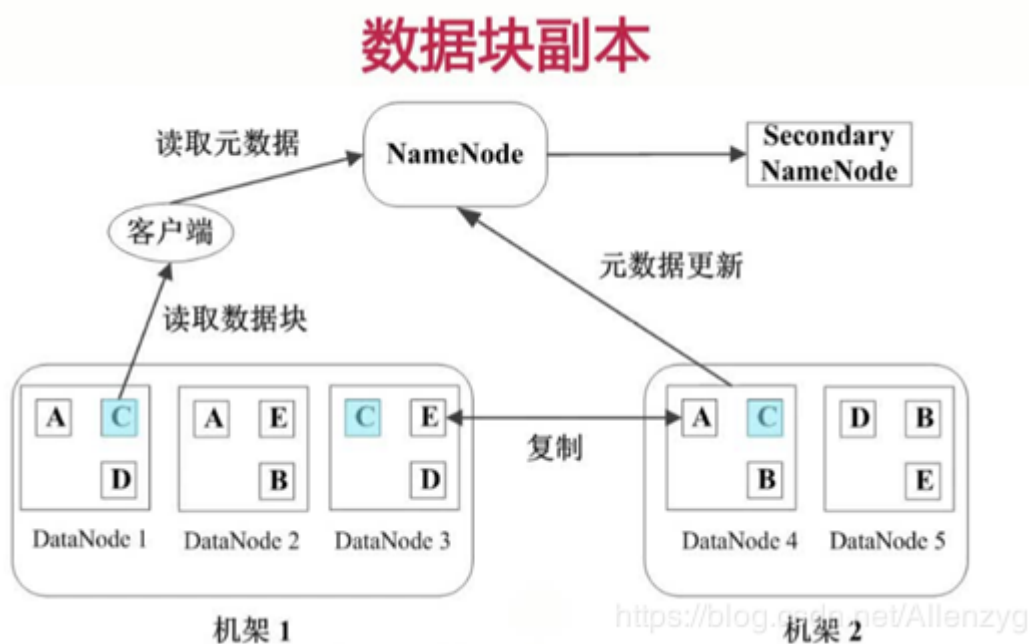
每块可以有多个副本

■ HDFS示意图



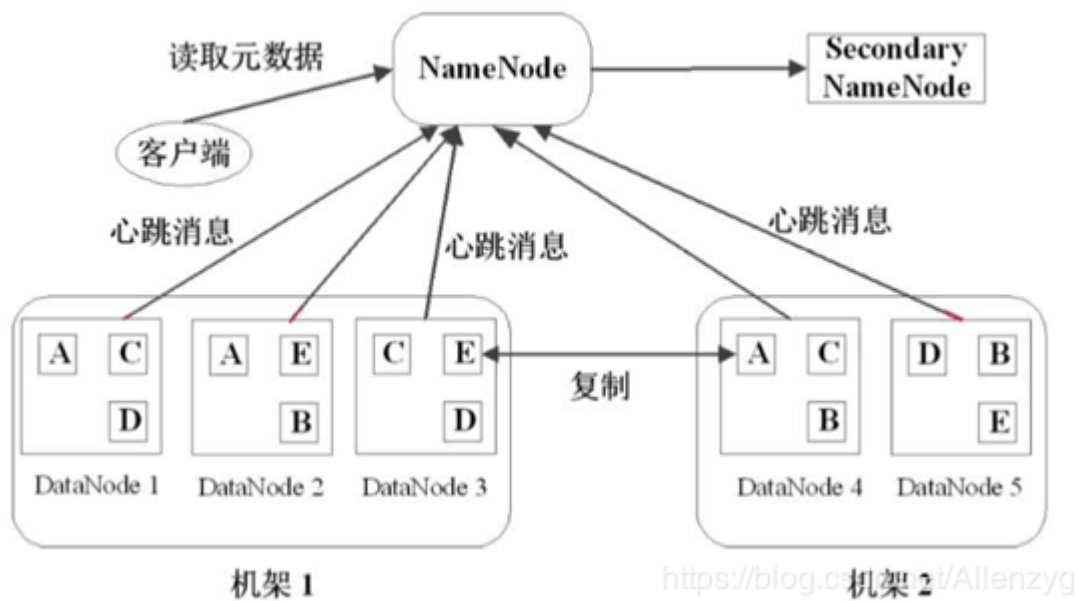
■ HDFS原理图

1、每个数据块3个副本，分布在两个机架内的节点，2个副本在同一个机架上的，另外一个副本在另外的机架上



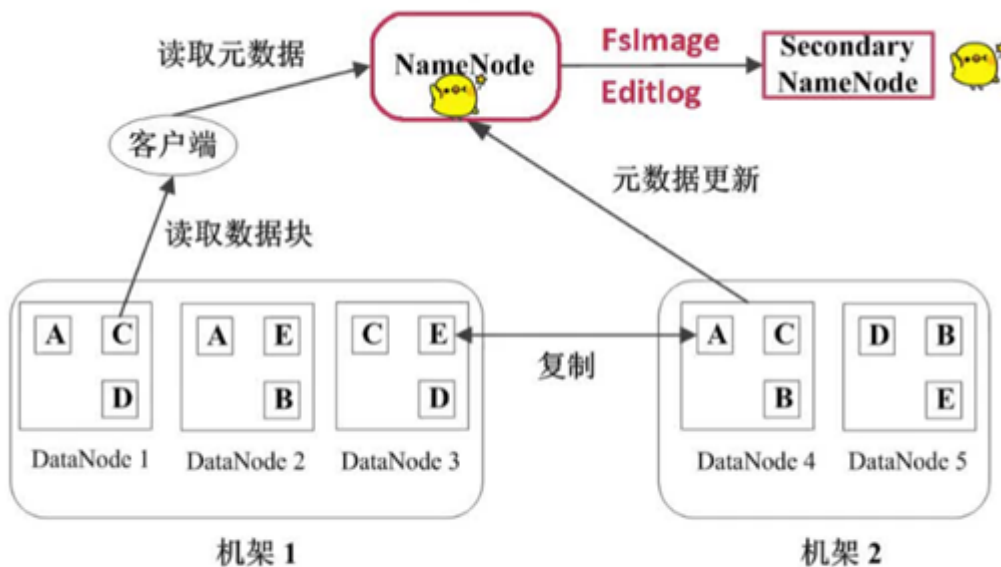
2、心跳检测，datanode定期向namenode发送心跳消息。查看是否有datanode挂掉了

心跳检测



3、secondary namenode;定期同步元数据映像文件和修改日志，namenode发生故障，secondaryname会成为主namenode

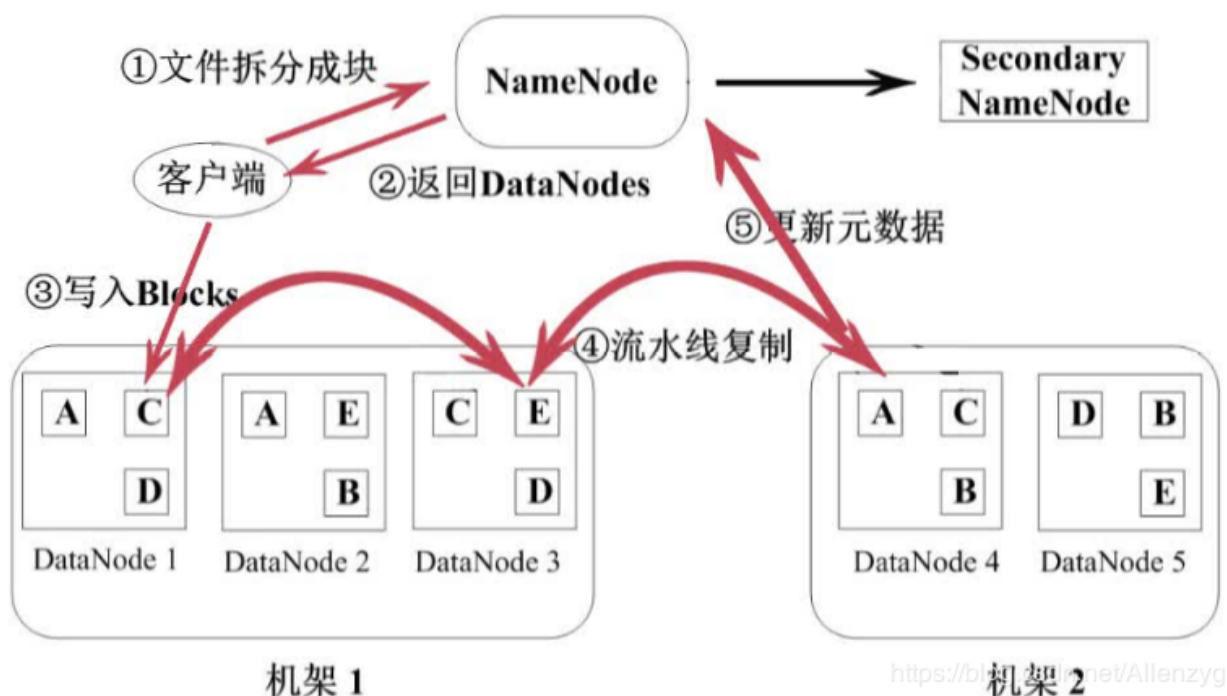
二级NameNode



二级NameNode定期同步元数据映像文件和修改日志
NameNode发生故障时，备胎转正😊

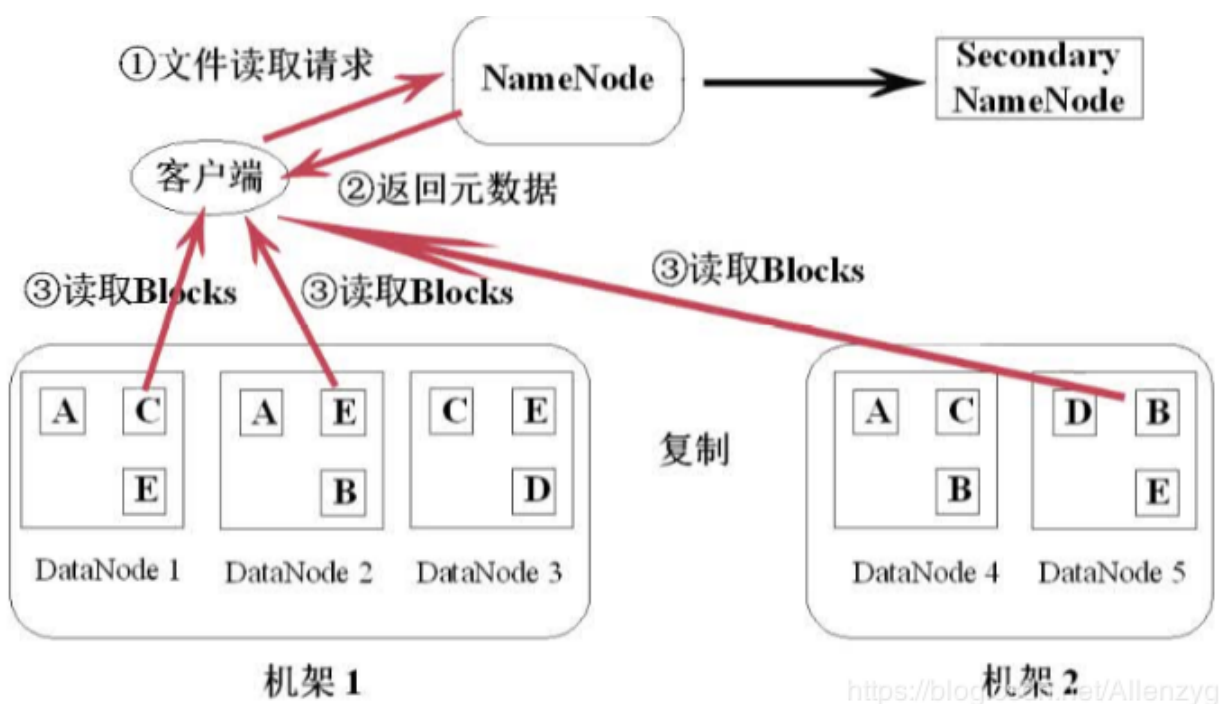
■ HDFS写文件流程

- 1 【1】 客户端将文件拆分成固定大小128M的块，并通知namenode
- 2 【2】 namenode找到可用的datanode返回给客户端
- 3 【3】 客户端根据返回的datanode，对块进行写入
- 4 【4】 通过流水线管道流水线复制
- 5 【5】 更新元数据，告诉namenode已经完成了创建新的数据块，保证namenode中的元数据都是最新的状态



■ HDFS读文件流程

- 1 【1】 客户端向namenode发起读请求，把文件名，路径告诉namenode
- 2 【2】 namenode查询元数据，并把数据返回客户端
- 3 【3】 此时客户端就明白文件包含哪些块，这些块在哪些datanode中可以找到

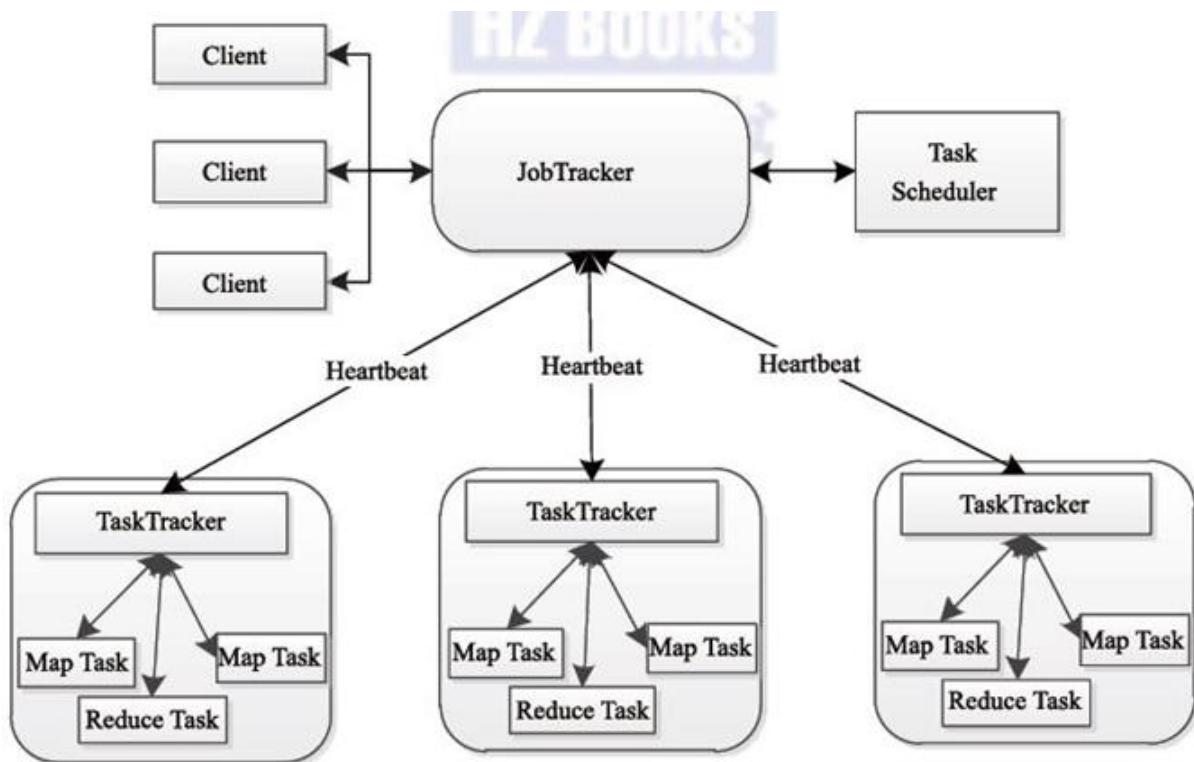


2.2.2 MapReduce

■ MapReduce实现了分布式计算

Hadoop的MapReduce是对google三大论文的MapReduce的开源实现，实际上是一种编程模型，是一个分布式的计算框架，用于处理海量数据的运算，由JAVA实现

■ MapReduce原理图



■ MapReduce角色及概念

1. JobTracker

- Master节点只有一个
- 管理所有作业/任务的监控、错误处理等
- 将任务分解成一系列任务，并分派给TaskTracker

2. TaskTracker

- Slave节点，一般是多台
- 运行Map Task和Reduce Task
- 并与JobTracker交互，汇报任务状态

3. Map Task

- 解析每条数据记录，传递给用户编写的map()并执行，将结果输出

4. Reducer Task

- 从Map Task的执行结果中，远程读取输入数据，对数据进行排序，将数据按照分组传递给用户编写的reduce函数执行

2.2.3 Yarn


■ 作用

负责整个集群资源的管理和调度，是Hadoop的一个通用的资源管理系统

■ 定义

Apache Hadoop YARN（Yet Another Resource Negotiator，另一种资源协调者）是一种新的 Hadoop 资源管理器，它是一个通用资源管理系统，可为上层应用提供统一的资源管理和调度，它的引入为集群在利用率、资源统一管理和数据共享等方面带来了巨大好处

■ 原理图



■ Yarn角色及概念

1. Resourcemanager
 - 处理客户端请求
 - 启动/监控ApplicationMaster
 - 监控NodeManager
 - 资源分配与调度
2. Nodemanager
 - 单个节点上的资源管理
 - 处理来自ResourceManager的命令
 - 处理来自ApplicationMaster的命令
3. ApplicationMaster
 - 为应用程序申请资源，并分配给内部任务
 - 任务监控与容错
4. Container
 - 对任务运行环境的抽象，封装了CPU、内存等
5. Client
 - 用户与Yarn交互的客户端程序
 - 提交应用程序、监控应用程序状态，杀死应用程序等

2.3 Hadoop总结

2.3.1 Hadoop组成

1. 分布式存储 - HDFS

2.3.2 HDFS特点

■ HDFS优点

1. 高可靠性
2. 高扩展性
3. 高效性
4. 高容错性
5. 低成本：与一体机、商用数据仓库等相比，hadoop是开源的，项目的软件成本因此会大大降低

■ HDFS缺点

1. 不能做到低延迟，由于hadoop针对高数据吞吐量做了优化，牺牲了获取数据的延迟，所以对于低延迟数据访问，不适合hadoop
2. 不适合大量小文件存储，由于namenode将文件系统的元数据存储在内存中，因此该文件系统所能存储的文件总数受限于namenode的内存容量，根据经验，每个文件、目录和数据块的存储信息大约占150字节
3. 对于上传到HDFS上的文件，不支持修改文件，HDFS适合一次写入，多次读取的场景

2.3.3 HDFS相关

■ 名词

1. NameNode
2. DataNode

■ 写入文件流程

1. 客户端将文件拆分成固定大小128M的块，并通知namenode
2. namenode找到可用的datanode返回给客户端
3. 客户端根据返回的datanode，对块进行写入
4. 通过流水线管道流水线复制
5. 更新元数据，告诉namenode已经完成了创建新的数据块，保证namenode中的元数据都是最新的状态

■ 读取文件流程

1. 客户端向namenode发起独立请求，把文件名，路径告诉namenode
2. namenode查询元数据，并把数据返回客户端
3. 此时客户端就明白文件包含哪些块，这些块在哪些datanode中可以找到

3. 环境安装

3.1 安装方式

■ 单机模式

只能启动MapReduce

■ 伪分布式

能启动HDFS、MapReduce 和 YARN的大部分功能

■ 完全分布式

能启动Hadoop的所有功能

3.2 安装JDK

3.2.1 JDK安装步骤

1. 下载JDK安装包（下载Linux系统的 .tar.gz 的安装包）

<https://www.oracle.com/java/technologies/javase/javase-jdk8-downloads.html>

2. 更新Ubuntu源

```
sudo apt-get update
```

3. 将JDK压缩包解压到Ubuntu系统中 /usr/local/ 中

```
sudo tar -zxvf jdk-8u251-linux-x64.tar.gz -C /usr/local/
```

4. 将解压的文件夹重命名为 jdk8

```
cd /usr/local/
```

```
sudo mv jdk1.8.0_251/ jdk8
```

5. 添加到环境变量

```
cd /home/tarena/
```

```
sudo gedit .bashrc
```

在文件末尾添加如下内容:

```
1 export JAVA_HOME=/usr/local/jdk8
2 export JRE_HOME=$JAVA_HOME/jre
3 export CLASSPATH=.:$JAVA_HOME/lib:$JRE_HOME/lib
4 export PATH=.:$JAVA_HOME/bin:$PATH
```

```
source .bashrc
```

6. 验证是否安装成功

```
java -version
```

<出现java的版本则证明安装并添加到环境变量成功 java version "1.8.0_251">

3.3 安装Hadoop并配置伪分布式

3.3.1 Hadoop安装配置步骤

1. 安装SSH

```
sudo apt-get install ssh
```

2. 配置免登录认证,避免使用Hadoop时的权限问题

```
ssh-keygen -t rsa （输入此条命令后一路回车）
```

```
cd ~/.ssh
```

```
cat id_rsa.pub >> authorized_keys
```

```
ssh localhost （发现并未让输入密码即可连接）
```

```
exit （退出远程连接状态）
```

3. 下载Hadoop 2.10 (374M)

<https://archive.apache.org/dist/hadoop/common/hadoop-2.10.0/hadoop-2.10.0.tar.gz>

4. 解压到 /usr/local 目录中,并将文件夹重命名为 hadoop, 最后设置权限

```
sudo tar -zxvf hadoop-2.10.0.tar.gz -C /usr/local/
```

```
cd /usr/local
```

```
sudo mv hadoop-2.10.0/ hadoop2.10
```

```
sudo chown -R tarena hadoop2.10/
```

5. 验证Hadoop

```
cd /usr/local/hadoop2.10/bin
```

```
./hadoop version (此处出现hadoop的版本)
```

6. 设置JAVE_HOME环境变量

```
sudo gedit /usr/local/hadoop2.10/etc/hadoop/hadoop-env.sh
```

把原来的export JAVA_HOME=\${JAVA_HOME}改为 export JAVA_HOME=/usr/local/jdk8

7. 设置Hadoop环境变量

```
sudo gedit /home/tarena/.bashrc
```

在末尾追加

```
1 export HADOOP_HOME=/usr/local/hadoop2.10
2 export CLASSPATH=.:${JAVA_HOME}/lib:${HADOOP_HOME}/sbin:$PATH
3 export PATH=.:${HADOOP_HOME}/bin:${HADOOP_HOME}/sbin:$PATH
```

```
source /home/tarena/.bashrc
```

8. 伪分布式配置, 修改2个配置文件 (core-site.xml 和 hdfs-site.xml)

9. 修改core-site.xml

```
sudo gedit /usr/local/hadoop2.10/etc/hadoop/core-site.xml
```

添加如下内容

```
1 <configuration>
2   <property>
3     <!--数据目录配置参数-->
4     <name>hadoop.tmp.dir</name>
5     <value>file:/usr/local/hadoop2.10/tmp</value>
6   </property>
7   <property>
8     <!--文件系统配置参数-->
9     <name>fs.defaultFS</name>
10    <value>hdfs://localhost:9000</value>
11  </property>
12 </configuration>
```

10. 修改hdfs-site.xml

```
sudo gedit /usr/local/hadoop2.10/etc/hadoop/hdfs-site.xml
```

添加如下内容

```

1 <configuration>
2   <property>
3     <!--副本数量-->
4     <name>dfs.replication</name>
5     <value>1</value>
6   </property>
7   <property>
8     <!--namenode数据目录-->
9     <name>dfs.namenode.name.dir</name>
10    <value>file:/usr/local/hadoop2.10/tmp/dfs/name</value>
11  </property>
12  <property>
13    <!--datanode数据目录-->
14    <name>dfs.datanode.data.dir</name>
15    <value>file:/usr/local/hadoop2.10/tmp/dfs/data</value>
16  </property>
17 </configuration>

```

11. 配置YARN - 1

```
cd /usr/local/hadoop2.10/etc/hadoop
```

```
cp mapred-site.xml.template mapred-site.xml
```

```
sudo gedit mapred-site.xml
```

添加如下配置

```

1 <property>
2   <name>mapreduce.framework.name</name>
3   <value>yarn</value>
4 </property>

```

12. 配置YARN - 2

```
sudo gedit yarn-site.xml
```

添加如下配置：

```

1 <property>
2   <name>yarn.nodemanager.aux-services</name>
3   <value>mapreduce_shuffle</value>
4 </property>

```

13. 执行NameNode格式化

```
cd /usr/local/hadoop2.10/bin
```

```
./hdfs namenode -format
```

出现 Storage directory /usr/local/hadoop2.10/tmp/dfs/name has been successfully formatted 则表示格式化成功

14. 启动Hadoop所有组件

```
cd /usr/local/hadoop2.10/sbin
```

```
./start-all.sh
```

启动时可能会出现警告，直接忽略即可，不影响正常使用

15. 启动成功后，可访问Web页面查看 NameNode 和 Datanode 信息，还可以在线查看 HDFS 中的文件

<http://localhost:50070>

16. 查看Hadoop相关组件进程

jps

会发现如下进程

1	NameNode
2	DataNode
3	SecondaryNameNode
4	ResourceManager
5	NodeManager

17. 测试 - 将本地文件上传至hdfs

hadoop fs -put 一个本地的任意文件 /

hadoop fs -ls /

也可以在浏览器中Utilities->Browse the file system查看

4. HDFS Shell操作

4.1 命令格式

hadoop fs 命令

4.2 常用命令汇总

■ 查看HDFS系统目录 (ls)

命令格式：hadoop fs -ls 路径

示例：hadoop fs -ls /

■ 创建文件夹 (mkdir)

命令格式1：hadoop fs -mkdir 绝对路径

命令格式2：hadoop fs -mkdir -p 绝对路径（可递归创建文件夹）

示例1：hadoop fs -mkdir /test

示例2：hadoop fs -mkdir -p /test/stu

■ 上传文件 (put)

命令格式：hadoop fs -put 本地文件 HDFS目录

示例：hadoop fs -put words.txt /test/

■ 下载文件 (get)

命令格式：hadoop fs -get HDFS文件 本地目录

示例：hadoop fs -get /test/words.txt /home/tarena/

■ 删除文件或目录 (rm)

命令格式1：hadoop fs -rm 文件或目录的绝对路径

命令格式2：hadoop fs -rm -r 目录（删除文件夹要加 -r 选项）

示例1：hadoop fs -rm /test/words.txt

示例2：hadoop fs -rm -r /test

■ 查看文件内容 (text)

命令格式：hadoop fs -text 文件绝对路径

示例：hadoop fs -text /test/words.txt

■ 移动 (mv)

命令格式：hadoop fs -mv 源文件 目标目录

示例：hadoop fs -mv /test/words.txt /words.txt

■ 复制 (cp)

命令格式：hadoop fs -cp 源文件 目标目录

示例：hadoop fs -cp /test/words.txt /words.txt

4.3 HDFS Shell操作练习

1. 在本地 /home/tarena/ 下新建 students.txt
2. 在students.txt中任意添加内容
3. 在HDFS中创建 /studir/stuinfo/ 目录
4. 将本地students.txt文件上传到HDFS中
5. 查看HDFS中 /studir/stuinfo/students.txt 的内容
6. 将HDFS中 /studir/stuinfo/students.txt 下载到本地命名为 new_students.txt
7. 删除HDFS中的 /studir 目录